
#### Almacenamiento y recuperación de información


### Trabajo 1 AWS-HADOOP-SPARK

Integrantes: Alejandro Arboleda Giron, Jhonatan Montes, Agustin Nieto, Rafael Alejandro Gil.


### 1. Creación del bucket y datalake




### Creación de las zonas y subida de datos a la zona raw




### 2. Creación de las bases de datos en Glue




#### Catalogación a partir del Crawler en Glue




#### Lectura de datos en athena sin procesar




## 3. Creación ETL para renombrar columnas



### Lectura de datos procesados en Athena




4. Creación cluster redshift para generar data-werehouse



Consumo de datos de datalake para generar el lakehouse


```
//Creamos una tabla externa//
create external schema clima_schema
from data catalog
database 'clima_db'
iam_role 'arn:aws:iam::801597884486:role/LabRole'
create external database if not exists;
create external table clima_schema.countryseries(
countrycode character(256),
seriescode varchar(256),
description character(256))
row format delimited
fields terminated by
stored as textfile
location 's3://aaja-trabajo1-datalake/raw/mundiales2/CCDRCountry-Series/'
table properties ('numRows'='172000');
select * from clima_schema.countryseries
where seriescode like '%"SeriesCode"%';;
//Creamos tabla nativa//
Create table ccdrSeriesTime(
SeriesCode varchar(200) distkey,
Year varchar(200) not null,
description varchar(200) not null);
COPY ccdrSeriesTime FROM 's3://aaja-trabajo1-datalake/raw/mundiales2/CCDRSeries-Time/CCDRSeries-Time.csv
delimiter ',' timeformat 'YYYY-MM-DD HH:MI:SS' region 'us-east-1';
Create table countryseries(
countrycode VARCHAR(256) distkey,
seriescode VARCHAR(256) not null,
doscription VARCHAR(256) not null)
```

### Lectura y join entre tablas externas con redshift




#### 5. Clúster AWS EMR.


Para crear un clúster en Amazon AWS lo primero es llamar el servicio EMR (Amazon Elastic MapReduce). Se debe ingresar en configuraciones avanzadas y de ahí seleccionar la versión EMR 6.3.1 seleccionar los siguientes servicios:




Luego escribimos el código de configuración escribiendo nuestro bucket de amazon de S3 en donde se guardarán nuestros notebooks de jupyter.




Escribimos el nombre de nuestro clúster



Y por último, antes de crear el clúster, seleccionamos la llave vockey que usamos para conectarnos a las máquinas. Finalmente damos click en crear el clúster.



Configuración de reglas de entrada: ingreso a grupos de seguridad en el master y adición de puertos 8888, 9443 y 8088.



Acciones ▼


Exportar los grupos de seguridad a CSV

1 > @


#### 6. Conexión Apache

Grupos de seguridad (1/2) Información


Para conectarse con servicios como Hue, Zepelling, spark, etc, se debe dirigir a la sección de historial de aplicaciones del cluster, en esta sección se deben haber generado links que envían a los servicios antes mencionados.




En Hive realizan consultas a la base de datos con los pasos de conexión del cluster a este servicio.




#### Query en Hive conectado a la base de datos.




7. Scripts en Zeppelin, comprobación de Spark y cague de DF




### Eliminamos la primera fila que se agregó como header



# Contamos la cantidad de registros y filtramos por país = colombia



### Contamos la cantidad de registros por país



### Segregamos el DF con las columnas countrycode

